

Informe Técnico

Prueba Técnica – Data Scientist Jr.

Álvaro José Cabrera Lozano

Modelo predictivo para producto de alto riesgo

Evaluación de modelos proveedores AB y XY

Contenido del entregable

Este documento sintetiza el análisis técnico de los puntos 1 y 2 de la prueba. Tanto el detalle del código, como las celdas reproducibles y las gráficas adicionales se encuentran en los notebooks `01_Modelo_ProductoNuevo.ipynb` y `02_Evaluacion_Proveedores.ipynb`. La presentación ejecutiva se encuentra en `Presentacion_Ejecutiva.ppt`.

Resumen ejecutivo

Punto 1 – Modelo Productivo Nuevo

Se construyó un modelo de clasificación para el producto que está dirigido al segmento de alto riesgo. La variable que se definió como la objetivo fue **Mora60**, pues es la que estaba mejor alineada con la definición operativa de default y con el costo real de incumplimiento. Se detectó y excluyó **data leakage** en la variable *MoraMax_UltimoSemestre* (Contenía la definición del target). El modelo final es una **Regresión Logística** con balanceo de clases, se validó mediante Out-Of-Time (OOT). Dicho esto, Se recomienda un punto de corte obtenido por análisis costo/beneficio que maximiza la ganancia esperada manteniendo un piso de aprobación del 25%

Punto 2 – Proveedores AB vs XY

Hallazgo Principal: **Ninguno de los dos modelos discrimina materialmente en el segmento** (AUC ~ 0.50, KS < 0.01, Gini ~ 0). Ambos puntajes son estables (PSI < 0.01) pero esta estabilidad pierde valor sin capacidad discriminante. Dicho esto, **se recomienda no contratar ninguno en su estado actual**. Sin embargo, si fuera obligatorio elegir, AB es marginalmente preferible por su cobertura del 100% (XY no atiende el 11% de la base) y menor costo operativo.

1. Modelo Producto Nuevo

1.1 Datos y EDA

La base ProductoNuevo contiene **4.315 clientes potenciales** evaluados entre enero de 2017 y septiembre de 2018, con 19 variables predictoras, estas se componen de un mix de demográficas, financieras y de comportamiento. Por otro lado, la tasa de mala global es del 24.4% para Mora30 y 11.7% para Mora60.

Los datos se trataron de la siguiente manera:

- Corrección de mojibake en variables categóricas (ej. T?RMINO INDEFINIDO = TERMINO INDEFINIDO)
- Winsorización al p99 para outliers en TiempoActividadAnios y GastoArriendo (preservando volumen sin sesgar)
- Construcción de razones financieras: arriendo_pct_ingreso, mas binning de la edad.

1.2 Hallazgo de importancia Crítica: Data Leakage

Durante el análisis univariado se identificó que la variable *MoraMax_UltimoSemestre* contenía prácticamente el target. Las tabulaciones cruzadas indicaron que el 100% de los clientes con $Mora60=1$ tienen $MoraMax_UltimoSemestre \geq 60$ y el 100% de los $Mora30=1$ tienen $MoraMax \geq 30$. Por lo que, la variable es la contención lógica del target (Muy probablemente fue construida como una marca derivada del mismo evento que se intenta predecir).

Por lo tanto, **la decisión tomada fue excluir *Mora_MaxUltimoSemestre* del set de predictoras**. Si esto no se hiciera, el modelo mostraría $KS \sim 1.0$ en la validación y fracasaría el modelo en producción, pues la variable no estaría disponible al momento del scoring. Dicho esto, el no detectar este tipo de leakage, sería la falta mas costosa del modelado en credit scoring.

1.3 Selección de variable objetivo

Se eligió *Mora60* sobre *Mora30* con base en 4 criterios:

Criterio	Mora30 (24.4%)	Mora60 (11.7%)
Severidad	Mora corta, recuperable	Deterioro real, mas alineado con default operativo
Costo del FN	Bajo (mora corta)	Alto (write-off, provision)
Apetito del riesgo	Sobreestima malos	Coherente con segmento de alto riesgo
Estabilidad	Sensible a estacionalidad	Mas robusta como señal

Adicionalmente, se validó cuantitativamente que el IV agregado de las predictoras se mantiene de manera comparable contra ambos targets, es decir, no hay perdida de material de señal predictiva al elegir *Mora60*.

1.4 Modelado y resultados

Se entrenaron dos modelos, una **Regresión Logística** con *class_weight=balanced*, debido a que es el estándar en la industria gracias a su interpretabilidad y trazabilidad regulatoria y **LightGBM**, regularizado como benchmark. Dicho esto, se utilizó el particionamiento **out-of-time** dejando los últimos 3 meses como hold-out (simulando un despliegue real).

Modelo	N	tasa_mala	AUC	Gini	KS
LogReg-train	3367	0.1182	0.6662	0.3324	0.2544

LogReg-test	842	0.1188	0.5628	0.1257	0.1724
LogReg-OOT	106	0.0566	0.665	0.33	0.39
LGBM-train	3367	0.1182	0.823	0.6459	0.4957
LGBM-test	842	0.1188	0.5783	0.1566	0.1699
LGBM-OOT	106	0.0566	0.665	0.33	0.55

La tabla nos indica que en out-of-time (OOT) ambos modelos llegan a una capacidad similar de Gini ~ 0.33 . La diferencia en KS es marginal y se inclina ligeramente a favor de LightGBM, pero no compensa la pérdida de interpretabilidad. **Se elige la Logística como modelo final**; LightGBM se conserva como challenger.




Ilustración 1 - Curvas ROC en muestra OOT -Logística vs LigthGBM.

1.5 Punto de corte recomendado

Para definir el corte se construyó una función de ganancia esperada asumiendo que la pérdida por aprobar a un malo (FN) equivale al 100% del valor del préstamo y la ganancia por aprobar un bueno (TN) es del 15% (margen comercial típico). Esta relación implica un costo asimétrico **$\sim 6.7x$** a favor de rechazar. Se exigió además un piso de aprobación del **25%** (viabilidad de negocio). El corte que maximiza la ganancia esperada bajo esa restricción es **PD < 0.60**.




Ilustración 2 - Tasa de aprobación vs riesgo residual y ganancia esperada por corte.

Se recomienda aprobar clientes con $PD < 0.60$ y monitorear mensualmente con PSI. De igual manera, se recomienda recalibrar si $PSI > 0.25$ o si la tasa de “mala” observada en aprobados se desvía mas de $\pm 30\%$ de la esperada por dos meses consecutivos.

2. Evaluación de proveedores AB vs XY

Se evaluaron los puntajes de los proveedores AB y XY sobre 114,109 clientes estudiados entre julio y septiembre de 2018, con tasa global de default del 60.4% (segmento de alto riesgo). El análisis cubre los cuatro ejes solicitados.

2.1 Capacidad discriminante

Proveedor	Cobertura	AUC	Gini	KS	PSI_max	PSI_Promedio
AB	1.0	0.5013	0.0026	0.0052	0.0015	0.0013
XY	0.8878	0.5018	0.0035	0.0051	0.0012	0.0011

Hallazgo principal: Podemos observar que ambos puntajes tienen AUC esencialmente igual a 0.50, KS por debajo de 0.01 y Gini cercano a cero. **Ninguno discrimina materialmente buenos de malos en este segmento.** La diferencia entre los dos modelos en los indicadores de discriminación no es prácticamente relevante.




Ilustración 3 - Curva ROC AB y XY - Ambas pegadas a la diagonal de azar.

2.2 Estabilidad del puntaje (PSI)

Mes	PSI_AB	PSI_XY
2018-08	0.0015	0.0009
2018-09	0.0011	0.0012

Ambos puntajes presentan una alta estabilidad temporal mes a mes, con valores de PSI inferiores a 0.01 y muy por debajo del umbral de alerta de 0.10. Esto indica que la distribución de los puntajes se mantiene estable frente al mes de referencia. Sin embargo, esta estabilidad debe interpretarse junto con el desempeño discriminante del modelo, ya que un puntaje puede ser estable en el tiempo, pero no necesariamente útil para diferenciar adecuadamente entre buenos y malos clientes.




Ilustración 4 - PSI mensual de cada proveedor contra el mes de referencia

2.3 Distribución por banda de score

La tabla decilica refuerza el diagnóstico: la tasa de mala se mantiene prácticamente plana en el ~60% en todas las bandas de score, en ambos modelos. Un modelo útil mostraría una tendencia monótona con concentración de malos en las bandas de mayor score.




Ilustración 5 - Tasa de mala por banda - ambos modelos plenos en torno al 60%

2.4 Cobertura y Missings

El proveedor XY no entrega score para 12.800 clientes (11.2% de la base). La tasa de default es prácticamente igual entre el segmento con

score y sin score, por lo que el missing no constituye un sub-segmento diferenciado. Sin embargo, contratar XY obligaría a la compañía a operar un **proceso paralelo** (otro modelo o regla manual) para esa fracción – costo operativo adicional sin contraparte en discriminación.

2.5 Recomendación

1. **Como primera opción no se recomienda contratar a ninguno en su estado actual.** Devolver los modelos a los proveedores con evidencia (curvas ROC pegadas a la diagonal, KS ~ 0 , decilica plana) y pedir recalibración sobre población análoga al segmento objetivo.
2. **Si la compañía debe elegir uno, el proveedor AB,** esto se sustenta en que AB cuenta con una cobertura del 100%, por lo que se evita un proceso paralelo. Por otro lado, cuenta con un PSI ligeramente mejor en el periodo evaluado. Finalmente, es importante tener en cuenta la estabilidad operativa superior. Pues, la diferencia estadística con XY no es relevante porque ambos discriminan al nivel del azar; la decisión se vuelve por tanto operativa, no analítica.
3. **Camino recomendado: Apalancar el modelo interno construido en el Punto 1,** complementarlo con buró de crédito propio o transaccional, y dejar a los proveedores como fuentes auxiliares solo si demuestran lift sobre el modelo interno en una validación cruzada.

3. Conclusiones, limitaciones y próximos pasos

3.1 Conclusiones

- El modelo interno desarrollado tiene capacidad discriminante razonable para el contexto (Gini OOT ~ 0.33 , KS ~ 0.39) y más importante, es trazable e interpretable.
- La detección del leakage en *MoraMax_UltimoSemestre* evita un riesgo de producción grave.
- La elección de Mora60 alinea el modelo con el costo real de la cartera.
- Los modelos de los proveedores no aportan valor en su forma actual; el modelo interno los supera.

3.2 Limitaciones

- Volumen limitado en la base modelado (4.315 registros, 504 malos en Mora60) por lo que el intervalo de confianza de las métricas es amplio
- Periodo de un solo año, por lo que no captura los ciclos macroeconómicos.
- Sin variables de buró ni transaccionales, tenemos una cota superior del Gini limitada
- El supuesto de costos (Pérdida 100%, ganancia 15%) debe validarse con el equipo financiero para ajustar el corte.

3.3 Próximos pasos sugeridos

1. Validar el modelo en una segunda muestra OOT cuando se acumulen 3-6 meses de originaciones bajo el corte recomendado.
2. Implementar tablero de monitoreo con KS, PSI, tasa de aprobación y tasa de mala observada por mes.
3. Pedir a los proveedores AB y XY explicación de la metodología y población de entrenamiento; en paralelo evaluar puntajes alternativos (buró tradicional, comportamiento transaccional propio).
4. Reentrenar el modelo cada 6 meses o cuando $PSI > 0.25$